



SAPIENZA
UNIVERSITÀ DI ROMA

A CNN-Based Approach for Brain Tumor Segmentation

Facoltà di Ingegneria dell'informazione, informatica e statistica
Corso di Laurea in Informatica

Daniele Bracoloni

Matricola 1985841

Relatore

Dott. Danilo Avola
Danilo Avola

Correlatore

Dott. Daniele Pannone

Anno Accademico 2024/2025

Tesi non ancora discussa

A CNN-Based Approach for Brain Tumor Segmentation
Sapienza Università di Roma

© Daniele Bracoloni. Tutti i diritti riservati

Questa tesi è stata composta con L^AT_EX e la classe Sapthesis.

Email dell'autore: bracoloni.1985841@studenti.uniroma1.it

Sommario

La segmentazione automatica dei tumori cerebrali da immagini di risonanza magnetica (MRI) rappresenta una delle sfide più importanti nell'ambito della diagnostica per immagini, in quanto consente di supportare il lavoro dei radiologi riducendo tempi e variabilità inter-osservatore. Negli ultimi anni, i modelli di *deep learning* e in particolare le reti di tipo **U-Net** hanno mostrato prestazioni promettenti in questo ambito. Questo lavoro di tesi presenta lo sviluppo e l'analisi di un modello di segmentazione basato su **U-Net 3D**, applicato al dataset **BraTS 2020**. L'obiettivo principale è stato quello di progettare una pipeline di segmentazione volumetrica **efficiente e accurata**, capace di ottenere buoni risultati anche in presenza di **risorse hardware limitate**. La metodologia adottata prevede l'elaborazione di patch tridimensionali (64, 64, 64), la normalizzazione Z-score dei volumi MRI multimodali (T1, T1ce, T2, FLAIR) e l'impiego di una funzione di perdita combinata **Focal + Dice Loss** per gestire lo sbilanciamento tra classi.

Il modello è stato addestrato con ottimizzatore Adam e tecniche di regolarizzazione quali **early stopping** e **model checkpoint**. I risultati ottenuti mostrano un **Dice globale medio pari a 0.73**, con alta precisione (0.93), sensibilità (0.85) e specificità (0.98), a testimonianza di una segmentazione accurata e coerente lungo l'asse tridimensionale. In conclusione, il lavoro dimostra che è possibile ottenere una segmentazione di buona qualità anche in condizioni computazionali limitate, proponendo un'architettura leggera e riproducibile che può rappresentare una base solida per futuri sviluppi, quali l'integrazione di moduli di attenzione o strategie di *domain adaptation*.

Indice

Acronomi	iv
1 Introduzione	1
1.1 Contesto e Motivazioni	1
1.2 Obiettivi e Contributi del Lavoro	1
1.3 Struttura del Documento	2
2 Background e Stato dell'Arte	3
2.1 Imaging Biomedico e Risonanza Magnetica	3
2.2 Formati NIfTI	4
2.3 Sequenze MRI e Maschere di Segmentazione	5
2.4 Tumori Cerebrali	6
2.5 Segmentazione di Immagini Mediche	6
2.6 Reti Neurali Convoluzionali (CNN)	6
2.7 U-Net e Architetture Derivate	7
2.7.1 Evoluzione nel Tempo	8
2.8 Stato dell'Arte	9
2.9 Sfide Aperte	9
3 Materiali e Metodi	11
3.1 Dataset BraTS 2020	11
3.1.1 Ground Truth: Maschere di Segmentazione	12
3.2 Step per la Segmentazione	12
3.3 Preprocessing dei Dati	13
3.3.1 Esperimenti	13
3.4 Architettura del Modello	13
3.4.1 Encoder	14
3.4.2 Decoder	14
3.4.3 Output Layer	15
3.4.4 Strategia di Addestramento	15
3.4.5 Confronto con varianti di U-Net più complesse	15
3.5 Implementazione	15
3.6 Setup Sperimentale	16
3.6.1 Hyperparameters	16
3.6.2 Training, Validation e Test Set	17
3.6.3 Strategie di Training	17

3.7	Metriche e Funzioni di Loss	18
3.7.1	Dice Similarity Coefficient (DSC)	18
3.7.2	Dice Loss	19
3.7.3	Focal Loss	19
3.7.4	Loss Combinata	20
4	Risultati e Discussione	21
4.1	Risultati Quantitativi	21
4.1.1	Risultati del Modello	21
4.1.2	Cosa misurano le metriche	22
4.1.3	Curve Di Training/Validation	23
4.2	Confronto con lo stato dell'arte	24
5	Conclusione	25
5.1	Conclusioni e considerazioni finali	25
	Bibliografia	27

Capitolo 1

Introduzione

1.1 Contesto e Motivazioni

La segmentazione dei tumori cerebrali tramite immagini di risonanza magnetica (MRI) rappresenta un compito fondamentale in ambito medico, poiché consente una diagnosi più accurata, una pianificazione terapeutica più mirata e un monitoraggio efficace della progressione della malattia. La segmentazione manuale effettuata dai neuroradiologi, sebbene considerata lo standard di riferimento, risulta tuttavia un processo lungo, dispendioso e soggetto a variabilità inter-osservatore. Negli ultimi anni, i metodi di *deep learning* hanno mostrato risultati promettenti nella segmentazione automatica di immagini biomediche, grazie alla loro capacità di apprendere rappresentazioni complesse direttamente dai dati. In particolare, l'architettura **U-Net**, introdotta da Ronneberger et al.⁽¹⁶⁾, è divenuta uno standard per le applicazioni di segmentazione in ambito biomedico, dimostrandosi particolarmente efficace anche con dataset di dimensioni limitate.

1.2 Obiettivi e Contributi del Lavoro

L'obiettivo di questo lavoro di tesi è lo sviluppo e l'analisi di un modello di segmentazione automatica dei tumori cerebrali basato su architettura **U-Net 3D**, applicato al dataset **BraTS 2020**. Il lavoro si concentra in particolare sull'adattamento e ottimizzazione del modello per essere eseguibile in modo efficiente su **hardware con risorse limitate**, mantenendo al contempo buone prestazioni di segmentazione volumetrica. Il contributo principale di questo elaborato consiste nello studio e nell'implementazione di una pipeline completa per la segmentazione MRI tridimensionale, che coniuga:

- una gestione efficiente della memoria tramite l'uso di **patch volumetriche 3D** di dimensioni ridotte;
- una **U-Net compatta e bilanciata**, capace di mantenere una buona accuratezza pur con un numero contenuto di parametri;
- una funzione di perdita **combinata (Dice + Focal Loss)** per gestire l'elevato sbilanciamento tra le classi;

- l'impiego di **strategie di training robuste** (data augmentation, early stopping e model checkpoint) per ottimizzare le prestazioni in contesti a risorse ridotte.

Oltre all'analisi quantitativa dei risultati ottenuti, il lavoro propone anche un confronto qualitativo tra approcci bidimensionali (2D) e tridimensionali (3D), con l'obiettivo di evidenziare l'impatto del contesto volumetrico nella coerenza spaziale della segmentazione.

1.3 Struttura del Documento

La tesi è articolata nei seguenti capitoli:

- **Capitolo 1** – Introduzione: presentazione del contesto, delle motivazioni e degli obiettivi del lavoro di tesi.
- **Capitolo 2** – Background e Stato dell'Arte: descrizione dei principi teorici dell'imaging biomedico, delle tecniche di segmentazione e dei modelli più recenti basati su deep learning.
- **Capitolo 3** – Materiali e Metodi: illustrazione del dataset BraTS2020, delle fasi di pre-processing, dell'architettura implementata e delle metriche di valutazione.
- **Capitolo 4** – Risultati e Discussione: analisi quantitativa e qualitativa dei risultati sperimentali, con confronto tra varianti e modelli.
- **Capitolo 5** – Conclusioni: sintesi dei risultati, limiti del lavoro e prospettive future.

Capitolo 2

Background e Stato dell'Arte

2.1 Imaging Biomedico e Risonanza Magnetica

L'imaging biomedico comprende un insieme di tecniche che permettono di visualizzare l'interno del corpo umano in maniera non invasiva. Tra queste, la **Risonanza Magnetica (MRI)** riveste un ruolo centrale nello studio del cervello, grazie alla sua capacità di fornire immagini ad alta risoluzione e con un'eccellente contrasto tra i diversi tessuti. Le principali sequenze MRI utilizzate per l'analisi dei tumori cerebrali sono:

- **T1**: struttura anatomica generale.
- **T1ce**: con contrasto, evidenzia la parte attiva del tumore.
- **T2**: sensibile all'acqua, evidenzia edemi.
- **FLAIR**: simile a T2 ma con soppressione liquidi.




Figura 2.1 Esempi di risonanze magnetiche. *Figura adattata da Menze et al.⁽¹⁵⁾, usata a scopo illustrativo accademico.*

Nella figura 2.1 ogni riga mostra differenti casi di tumore cerebrale, nelle varie modalità MRI (FLAIR, T2 e T1ce). Le linee blu indicano le annotazioni fornite dai

singoli esperti, mentre le linee magenta rappresentano la segmentazione di consenso. L'immagine evidenzia come ogni sequenza MRI metta in risalto differenti regioni patologiche (tumore totale, nucleo e parte attiva).

2.2 Formati NIfTI

I file *Neuroimaging Informatics Technology Initiative* (NIfTI, estensione `.nii`) sono file multidimensionali, tipicamente tridimensionali (x,y,z) o quadridimensionali (x,y,z,t), molto utilizzati in ambito medico, in particolare per immagini di risonanza magnetica (MRI). Essi contengono una sequenza di slice (immagini bidimensionali) che, impilate lungo l'asse della profondità, costituiscono l'intero volume tridimensionale. Ogni elemento dell'immagine è chiamato *voxel* (volume element), analogo al pixel per le immagini 2D, e viene identificato da tre coordinate spaziali:

- **Asse X:** rappresenta la dimensione orizzontale, ovvero la larghezza del volume.
- **Asse Y:** rappresenta la dimensione verticale, ovvero l'altezza del volume.
- **Asse Z:** rappresenta la profondità del volume, ovvero il numero di slice che compongono l'immagine.

Ad esempio, un voxel con coordinate (100, 100, 50) identifica il punto situato alla colonna 100, riga 100, nella slice numero 50. Per lo studio di patologie come i tumori cerebrali non è tuttavia sufficiente considerare un singolo voxel, ma risulta più significativo analizzare regioni tridimensionali più estese per cogliere la struttura complessiva della lesione.




Figura 2.2 Visualizzazione del volume tridimensionale MRI (T1ce). Visualizzazione dell'intero volume MRI in modalità *montage*, ottenuta concatenando tutte le slice bidimensionali della sequenza T1ce.

Ogni immagine rappresenta una sezione del cervello lungo l'asse Z , che corrisponde alla profondità del volume. In questo modo è possibile osservare l'estensione del tumore e la sua distribuzione attraverso le diverse slice che compongono il volume tridimensionale. La dimensione X rappresenta la larghezza, Y l'altezza e Z il numero di slice. Come si può osservare, ai margini del *montage* sono presenti due aree nere. Queste corrispondono alle prime e ultime slice del volume, che rappresentano le estremità del cervello. Ciò indica che una parte consistente delle slice non contiene informazioni rilevanti, il che è del tutto atteso poiché le immagini rappresentano progressivamente il cervello da un'estremità all'altra. Questa osservazione è coerente in tutte le modalità MRI, nei diversi piani di acquisizione e persino nelle maschere di segmentazione realizzate dagli esperti.

2.3 Sequenze MRI e Maschere di Segmentazione

Come anticipato, per ogni paziente del dataset vengono fornite quattro sequenze di risonanza magnetica (MRI), ciascuna salvata in un file `.nii` (formato NIfTI). Ogni sequenza mette in evidenza aspetti differenti della patologia tumorale, fornendo informazioni complementari:

- **T1-pesata (T1):** offre una chiara rappresentazione della struttura anatomica del cervello, utile per identificare i confini generali tra tessuti.
- **T1 con contrasto (T1ce):** evidenzia le regioni attive e aggressive del tumore grazie all'iniezione di mezzo di contrasto, mettendo in risalto la porzione *enhancing*.
- **T2-pesata (T2):** particolarmente sensibile alla quantità di acqua nei tessuti, consente di osservare aree anomale associate a patologie (edema, infiammazioni).
- **FLAIR (Fluid Attenuated Inversion Recovery):** simile alla T2, ma con soppressione del segnale dei fluidi, che rende più visibili gli edemi peritumorali.

Accanto a queste sequenze, è fornita una **maschera di segmentazione**, anch'essa in formato `.nii`, realizzata manualmente da esperti neuroradiologi. La maschera contiene le etichette numeriche che identificano le varie sottoregioni del tumore:

- 0 = **tessuto sano**,
- 1 = **nucleo necrotico/non-enhancing (NCR/NET)**,
- 2 = **edema peritumorale (ED)**,
- 4 = **tumore enhancing (ET)**.

Dal punto di vista tecnico, ogni file NIfTI è un volume tridimensionale costituito da una matrice $X \times Y \times Z$, dove ogni elemento rappresenta un *voxel* (analogo 3D del pixel). Per le immagini MRI, l'intensità numerica di ciascun voxel descrive il segnale acquisito dal tessuto in quella posizione, che varia a seconda della sequenza (T1,

T1ce, T2 o FLAIR). Nel caso della maschera, invece, ogni voxel non rappresenta un'intensità, ma un'etichetta intera che specifica la classe di appartenenza (tumore o tessuto sano). In sintesi, per ciascun paziente si hanno quindi **cinque file NIfTI**: quattro corrispondenti alle sequenze MRI e uno relativo alla maschera di segmentazione manuale.

2.4 Tumori Cerebrali

I tumori cerebrali rappresentano una delle patologie più complesse e gravi in ambito medico. Tra questi, i **gliomi** sono i più comuni e vengono classificati dall'Organizzazione Mondiale della Sanità (OMS) in diversi gradi di malignità. L'identificazione accurata delle regioni tumorali è fondamentale per:

- la diagnosi,
- la pianificazione del trattamento,
- il monitoraggio della progressione della malattia.

Tuttavia, la segmentazione manuale è dispendiosa in termini di tempo e soggetta a variabilità inter-osservatore.

2.5 Segmentazione di Immagini Mediche

La segmentazione consiste nel suddividere un'immagine in regioni omogenee, al fine di identificare strutture di interesse. Negli anni sono stati sviluppati diversi approcci:

- **Metodi tradizionali:** thresholding, region growing, watershed.
- **Machine Learning classico:** classificatori come Random Forest e Support Vector Machine.
- **Deep Learning:** approcci basati su reti neurali convoluzionali (CNN).

L'avvento del deep learning ha portato a un salto di qualità, permettendo di ottenere performance superiori rispetto ai metodi precedenti.

2.6 Reti Neurali Convoluzionali (CNN)

Le CNN sono reti progettate per l'elaborazione di immagini, caratterizzate da livelli convoluzionali che estraggono automaticamente le caratteristiche più rilevanti dai dati. In ambito medico, le CNN vengono utilizzate sia per la classificazione che per la segmentazione, grazie alla loro capacità di gestire dati volumetrici e di apprendere pattern complessi difficilmente modellabili con approcci tradizionali.

2.7 U-Net e Architetture Derivate

L'architettura **U-Net**, proposta da Ronneberger et al.⁽¹⁶⁾ nel 2015, è un'architettura di Rete Neurale Convolutionale (CNN) progettata per la segmentazione rapida e precisa delle immagini, diventata lo standard per la segmentazione di immagini biomediche. La sua struttura a forma di "U", visibile in Figura 2.3, è composta da due rami principali: un **encoder** (o percorso di contrazione) e un **decoder** (o percorso di espansione), collegati tra loro tramite *skip connections* (sono collegamenti che "saltano" alcuni livelli della rete e uniscono direttamente i dati di un livello dell'encoder con quelli del corrispondente livello del decoder.). L'encoder (a sinistra) riduce progressivamente la risoluzione per estrarre feature di alto livello, mentre il decoder (a destra) ricostruisce la mappa di segmentazione combinando informazioni locali e globali tramite connessioni a salto.




Figura 2.3 Schema concettuale dell'architettura U-Net classica proposta da Ronneberger et al.⁽¹⁶⁾. *Figura adattata da Roy et al.⁽⁴⁾, pubblicato su IEEE Access (2023), usata a scopo illustrativo accademico.*

Nel **percorso di contrazione**, l'immagine in ingresso viene elaborata attraverso più blocchi di convoluzione seguiti da operazioni di *max pooling* (operazione che riduce la dimensione spaziale di un'immagine o di una feature map, mantenendo solo le informazioni più importanti). Ogni livello riduce la risoluzione spaziale ma aumenta il numero di feature maps, consentendo alla rete di catturare informazioni sempre più astratte e globali. Questo processo permette di riconoscere il contesto e la struttura generale dell'immagine. Nel **percorso di espansione**, avviene l'operazione inversa: la risoluzione viene gradualmente ripristinata tramite operazioni di *upsampling* o *deconvoluzione*, mentre il numero di feature maps diminuisce. A ogni livello, le feature upscalate vengono concatenate con le corrispondenti feature del percorso discendente tramite le *skip connections*. Queste connessioni a salto sono fondamentali, poiché

reintegrano i dettagli spaziali persi durante il downsampling, migliorando la precisione dei bordi e la localizzazione fine delle strutture segmentate. Infine, uno strato di convoluzione 1×1 genera la mappa di output, in cui a ciascun pixel (o voxel, nel caso 3D) viene assegnata una classe di appartenenza. L'architettura U-Net è quindi in grado di combinare in modo efficace le **informazioni globali** (ottenute dall'encoder) e le **informazioni locali** (ripristinate dal decoder), garantendo segmentazioni accurate anche in presenza di dataset di piccole dimensioni.

2.7.1 Evoluzione nel Tempo

A partire dall'architettura originale di U-Net proposta da Ronneberger et al.⁽¹⁶⁾, sono state sviluppate numerose varianti mirate a migliorarne la capacità di generalizzazione, la stabilità e l'efficienza. La **3D U-Net** ha esteso le operazioni convoluzionali al dominio volumetrico, consentendo l'elaborazione diretta di volumi tridimensionali e una più accurata modellazione della coerenza spaziale tra slice consecutive. Successivamente, la **Residual U-Net** ha introdotto connessioni residue, ispirate alle ResNet, per facilitare la propagazione del gradiente e rendere più stabile l'addestramento di reti profonde. L'**Attention U-Net** ha integrato meccanismi di attenzione che permettono al modello di focalizzarsi sulle regioni più rilevanti dal punto di vista patologico, riducendo i falsi positivi. Infine, la **nnU-Net** ha rappresentato un'evoluzione metodologica, configurandosi come un framework auto-ottimizzante capace di adattare automaticamente iperparametri e pipeline di preprocessing al dataset in analisi. Nel presente lavoro viene implementata una **U-Net 3D compatta**, ispirata a tali architetture, che combina convoluzioni volumetriche, connessioni residue e normalizzazione per gruppi.




Figura 2.4 Esempio di architettura U-Net 3D evoluta per la segmentazione di tumori cerebrali da immagini MRI multimodali. L'input combina le sequenze *T1ce*, *T2*, *FLAIR*; il modello utilizza convoluzioni tridimensionali, blocchi residui e connessioni a salto per produrre una mappa di segmentazione volumetrica. *Figura adattata da Roy et al.⁽⁴⁾, pubblicato su IEEE Access (2023), usata a scopo illustrativo accademico.*

2.8 Stato dell'Arte

Negli ultimi anni, la segmentazione automatica dei tumori cerebrali da immagini di risonanza magnetica (MRI) ha beneficiato di un forte impulso grazie alle iniziative di benchmarking come la **BraTS Challenge**^(12;13;15). Queste competizioni hanno fornito dataset standardizzati e metriche comuni, stimolando lo sviluppo di modelli di *deep learning* sempre più accurati e generalizzabili. In origine, la segmentazione era affrontata con metodi di *machine learning* classico, come Support Vector Machine e Random Forest, combinati con estrazione manuale di feature radiomiche⁽¹⁴⁾. Tali approcci, seppur promettenti, risultavano poco scalabili e sensibili alle variazioni di intensità tra scanner diversi. L'avvento delle *Convolutional Neural Networks* (CNN) ha segnato un cambiamento decisivo. In particolare, **Ronneberger et al. (2015)**⁽¹⁶⁾ introdussero la **U-Net**, un'architettura encoder-decoder con connessioni a salto (*skip connections*) capace di combinare informazioni globali e locali. Grazie alla sua efficienza e all'uso di *data augmentation*, la U-Net è diventata rapidamente lo standard nella segmentazione biomedica. Negli anni successivi, sono emerse numerose varianti che ne hanno esteso le potenzialità. La **3D U-Net** ha permesso di analizzare interi volumi tridimensionali; la **Residual U-Net** ha introdotto connessioni residue per facilitare l'addestramento; mentre la **Attention U-Net** ha integrato meccanismi di attenzione per evidenziare le regioni rilevanti. Più recentemente, modelli come **nnU-Net**, **UNETR** e **Swin-UNETR** hanno combinato CNN e *Transformer*, adattando automaticamente la pipeline ai dati^(1;4;7;8). Nel contesto delle BraTS Challenge più recenti, architetture U-Net ottimizzate, come quelle di **Futrega et al. (2021)** e **Roy et al. (2023)**, hanno raggiunto valori di *Dice* medio superiori a 0.88, grazie all'integrazione di blocchi di attenzione e meccanismi di supervisione profonda. Questi risultati confermano l'efficacia delle reti convoluzionali profonde nella segmentazione multimodale (T1, T1ce, T2, FLAIR) e nella distinzione delle diverse componenti tumorali. In sintesi, le architetture basate su U-Net rappresentano oggi lo standard di riferimento per la segmentazione dei tumori cerebrali. Tuttavia, restano aperte sfide legate alla generalizzazione su dati multi-istituzionali, allo sbilanciamento tra classi e all'elevato costo computazionale dei modelli tridimensionali.

2.9 Sfide Aperte

Nonostante i notevoli progressi ottenuti, la segmentazione automatica dei tumori cerebrali presenta ancora sfide significative che limitano l'applicabilità clinica dei modelli di *deep learning*. Tra le principali problematiche si evidenziano:

- **Elevata variabilità inter-paziente**, dovuta alle differenze morfologiche e istologiche dei tumori, che rendono difficile la generalizzazione dei modelli su pazienti mai visti in fase di addestramento.
- **Sbilanciamento tra le diverse classi**, poiché alcune regioni come la necrosi o il tumore in crescita attiva occupano volumi molto più piccoli rispetto all'edema o al tessuto sano, causando una perdita di sensibilità nelle aree minori.

- **Difficoltà di generalizzazione su dataset multi-istituzionali**, legate alle differenze di protocolli di acquisizione, scanner MRI e qualità delle annotazioni.
- **Dipendenza dai dati annotati**, poiché la creazione di maschere di segmentazione manuali da parte di esperti è un processo dispendioso e soggetto a variabilità inter-osservatore.
- **Elevato costo computazionale** dei modelli 3D, che limita la loro implementazione in contesti clinici in tempo reale o su hardware con risorse limitate.

Per affrontare tali problematiche, la ricerca più recente si sta orientando verso strategie di *domain adaptation*, *semi-supervised learning* e *federated learning*, nonché verso l'impiego di architetture ibride (CNN–Transformer) capaci di catturare relazioni spaziali e contestuali su larga scala. Tali approcci mirano a migliorare la robustezza e la trasferibilità dei modelli, favorendo la loro integrazione in sistemi di supporto alle decisioni cliniche realmente affidabili e generalizzabili.

Capitolo 3

Materiali e Metodi

3.1 Dataset BraTS 2020

Il dataset BraTS 2020 (Multimodal Brain Tumor Segmentation Challenge), scaricato dalla piattaforma Kaggle, rappresenta uno standard di riferimento per la valutazione di algoritmi di segmentazione dei gliomi, i tumori cerebrali più comuni. Tutti i 369 pazienti di cui è composto il dataset presentano un tumore cerebrale, ma con differente livello di estensione e aggressività. Questa variabilità incide sulla complessità delle immagini e delle maschere di segmentazione, poiché alcuni casi mostrano lesioni più ampie e facilmente distinguibili, mentre altri presentano tumori di dimensioni ridotte o con margini meno definiti. Per ciascun soggetto sono fornite quattro sequenze di risonanza magnetica (MRI), salvate in formato NIfTI (.nii) con grandezza di (240,240,155) voxels.




Figura 3.1 Esempio di slice centrale di un paziente del dataset BraTS 2020, rappresentata nelle quattro modalità di risonanza magnetica (T1, T1 con mezzo di contrasto, T2 e FLAIR) la corrispondente maschera di segmentazione, e in aggiunta, la sovrapposizione tra Flair e la maschera di segmentazione.

3.1.1 Ground Truth: Maschere di Segmentazione

Le maschere di segmentazione manuale, considerate come ground truth, sono state annotate da esperti neuroradiologi. Esse identificano le seguenti classi:

- **Etichetta 0:** Tessuto cerebrale sano.
- **Etichetta 1:** Nucleo necrotico/non-enhancing (NCR/NET).
- **Etichetta 2:** Edema peritumorale (ED).
- **Etichetta 4:** Tumore enhancing (ET).

Il compito del modello è predire, per ogni voxel, l'etichetta corretta, permettendo così di localizzare e quantificare le regioni tumorali.

L'analisi combinata di queste sequenze consente di distinguere le diverse componenti del tumore in base all'intensità del segnale.

In particolare:

- se in **T1ce** un voxel appare brillante, è probabile che appartenga al **tumore in fase di enhancement (classe 4)**;
- se è iperintenso in **FLAIR** ma non in T1ce, può corrispondere a un'area di **edema peritumorale (classe 2)** o a un **nucleo non-enhancing (classe 1)**;
- se nessuna sequenza mostra anomalie, il voxel viene considerato **tessuto sano (classe 0)**.

Queste differenze radiologiche costituiscono la base del processo di annotazione manuale e permettono al modello di apprendere la relazione tra pattern d'intensità e regioni patologiche.




Figura 3.2 Esempio di maschera di segmentazione nel dataset BraTS2020. È mostrata la maschera completa (a sinistra) e la suddivisione nelle singole classi: tessuto sano (classe 0), nucleo necrotico/non-enhancing (classe 1), edema peritumorale (classe 2) e tumore enhancing (classe 4). Ogni colore rappresenta una regione patologica distinta.

3.2 Step per la Segmentazione

Una pipeline tipica di segmentazione di tumori cerebrali basata su CNN comprende tre fasi principali:

1. **Preprocessing:** normalizzazione delle intensità, resize delle immagini, rimozione del cranio (skull stripping) e altre trasformazioni.

2. **Training:** addestramento del modello mediante dataset annotato e funzioni di perdita adeguate.
3. **Testing:** valutazione del modello su dati non visti per verificare la capacità di generalizzazione.

3.3 Preprocessing dei Dati

Il dataset BraTS è già fornito con alcuni preprocessing standard: le immagini sono co-registrate su un template anatomico comune, interpolate a risoluzione isotropica 1 mm^3 e skull-stripped.

Ulteriori passaggi implementati in questo lavoro sono:

1. **Stacking dei Canali:** le quattro sequenze MRI sono state impilate lungo un asse canale, creando un tensore in formato (C, H, W, D), dove: C-channels, H-height, W-width and D-depth, nel nostro caso verrà generato un tensore $(4 \times 240 \times 240 \times 155)$.
2. **Normalizzazione:** applicata una normalizzazione Z-score per standardizzare le intensità dei voxel. Questo processo riduce le differenze dovute a variazioni di acquisizione (scanner, parametri o pazienti) e stabilizza l'addestramento del modello, rendendo i valori numerici confrontabili e favorendo una convergenza più rapida durante il training.

3.3.1 Esperimenti

Per addestrare la rete neurale sono state valutati diverse strategie e sono stati effettuati degli esperimenti per verificare quale fosse l'opzione migliore. Sono state valutate due diverse strategie di suddivisione del volume MRI in sotto-regioni:

- **Patch 2D:** estratte come slice bidimensionali indipendenti. Questa scelta riduce i costi computazionali e consente un training più rapido, ma comporta la perdita di informazioni volumetriche lungo l'asse Z .
- **Patch 3D:** estratte come cubi tridimensionali $(64 \times 64 \times 64)$. Ho scelto di concentrarmi sullo sviluppo di un modello a base di Patch 3D in modo tale da conservare la continuità spaziale, migliorando la capacità della rete di cogliere la morfologia del tumore, a discapito di un maggior uso di memoria e tempi di addestramento più lunghi.

3.4 Architettura del Modello

Il modello scelto è la **3D U-Net**, una rete neurale convoluzionale con struttura encoder-decoder e connessioni a salto (skip-connections). Essa consente di combinare informazioni contestuali (encoder) con dettagli spaziali (decoder), garantendo segmentazioni precise. L'architettura è progettata per elaborare patch volumetriche di risonanze magnetiche (MRI) e produrre mappe di segmentazione voxel-wise multiclasse (background, necrosi, edema, tumore in contrasto).




Figura 3.3 Esempio di pipeline di segmentazione di tumori cerebrali da MRI, comprendente le fasi di pre-processing, addestramento e valutazione. *Figura adattata da Kaur et al., "MRI-based brain tumor segmentation using deep learning and hybrid models: a review", BMC Medical Imaging (2023)⁽³⁾. Usata a scopo illustrativo accademico.*

3.4.1 Encoder

L'encoder riduce progressivamente la risoluzione spaziale dell'input aumentando il numero di feature maps, così da estrarre rappresentazioni gerarchiche e di alto livello.

- Il volume in input (nel nostro caso una patch $64 \times 64 \times 64$ con 4 canali multimodali) è elaborato da due layer convoluzionali con kernel $3 \times 3 \times 3$, 16 filtri, ciascuno seguito da Batch Normalization e attivazione ReLU.
- Un layer di MaxPooling3D con stride pari a 2 dimezza la risoluzione spaziale e raddoppia il numero di filtri ($16 \rightarrow 32$).
- Lo stesso schema si ripete: due convoluzioni con 32 filtri, seguite da un pooling che porta a una rappresentazione con 64 feature maps al livello di bottleneck.

3.4.2 Decoder

Il decoder ricostruisce la risoluzione originale tramite operazioni di upsampling e concatenazioni con le feature corrispondenti provenienti dall'encoder (skip connections), mantenendo così i dettagli locali.

- Un layer di UpSampling3D raddoppia la risoluzione e il risultato viene concatenato con le feature dell'encoder al livello corrispondente.
- Due convoluzioni $3 \times 3 \times 3$ raffinano le feature (prima con 32 filtri, poi con 16 filtri).
- Il processo si ripete fino al recupero della risoluzione spaziale originale.

3.4.3 Output Layer

Alla risoluzione finale, una convoluzione $1 \times 1 \times 1$ proietta le feature maps in quattro canali, uno per ciascuna classe (background, necrosi, edema, tumore in contrasto). L'attivazione softmax fornisce le probabilità voxel-wise per ogni classe.

3.4.4 Strategia di Addestramento

Il modello è stato addestrato utilizzando l'ottimizzatore **Adam** con un learning rate pari a 1×10^{-4} . Per gestire lo sbilanciamento tra le diverse classi tumorali è stata impiegata una **funzione di perdita combinata**, costituita dalla somma pesata di *Dice Loss* e *Focal Loss*, in modo da bilanciare l'apprendimento tra le regioni dominanti (tessuto sano, edema) e quelle meno rappresentate (necrosi, tumore enhancing). Come metriche di valutazione sono stati monitorati l'**accuratezza globale** e il **coefficiente di Dice** (sia complessivo sia per singola classe), al fine di valutare la qualità della segmentazione voxel-wise e la sovrapposizione tra predizione e ground truth.

3.4.5 Confronto con varianti di U-Net più complesse

La nostra implementazione è relativamente compatta (tre livelli di downsampling, massimo 64 filtri), caratteristica che la rende adatta a GPU con memoria limitata e a dataset di dimensioni ridotte. Al contrario, approcci allo stato dell'arte come nnU-Net o Optimized U-Net⁽⁷⁾ impiegano architetture più profonde (fino a sette livelli e 512 filtri) e meccanismi aggiuntivi come deep supervision e attenzione. Tuttavia, il nostro modello compatto rappresenta una baseline stabile per ulteriori esperimenti.

3.5 Implementazione

L'implementazione è stata realizzata in Python utilizzando librerie come **TensorFlow/Keras** per la definizione e l'addestramento del modello, **NiBabel** per la gestione dei file NIfTI, e strumenti di *data augmentation* per incrementare la varietà dei dati di training. La pipeline include:

- Caricamento e preprocessing delle immagini;
- Creazione di patch tridimensionali;
- Definizione del modello U-Net;
- Training loop con salvataggio dei checkpoint.

Le immagini MRI multimodali (*T1*, *T1ce*, *T2*, *FLAIR*) e le maschere di segmentazione vengono lette e normalizzate tramite la funzione `load_patches()`, che genera per ciascun paziente un insieme di *patch 3D* bilanciate contenenti tessuti tumorali e sani. La funzione `data_generator()` gestisce invece la produzione dinamica dei batch durante l'addestramento, richiamando `load_patches()` per ciascun soggetto e restituendo blocchi di dati e maschere pronti per essere utilizzati nel modello. Questa strategia consente di addestrare reti 3D anche con dataset voluminosi, evitando di

caricare in memoria l'intero volume cerebrale e garantendo una maggiore diversità spaziale nelle regioni osservate dal modello.




Figura 3.4 Schema generale di un processo di segmentazione di tumori cerebrali da immagini MRI, che comprende fasi di pre-processing, estrazione di feature e classificazione. *Figura adattata da Dhanachandra et al., "Multimodal MRI Brain Tumor Image Segmentation Using Sparse Subspace Clustering Algorithm", (2020)⁽¹⁰⁾. Usata a scopo illustrativo accademico.*

3.6 Setup Sperimentale

3.6.1 Hyperparameters

- Ottimizzatore: Adam
- Learning rate: 1×10^{-4}
- Batch size: 2
- Patch size: (64, 64, 64)
- Numero epoche: 15

Durante l'implementazione del modello tridimensionale, sono state testate diverse combinazioni di iperparametri per valutare l'impatto di ciascuno sulle prestazioni del modello. Un aumento della *patch size* (ad esempio (128, 128, 128)) consente di

catturare un contesto spaziale più ampio e tende a migliorare la capacità di generalizzazione della rete. Tuttavia, ciò comporta un notevole incremento del consumo di memoria GPU. Con l'hardware a disposizione (6GB VRAM), il compromesso ottimale è stato raggiunto con *patch* di dimensione (64, 64, 64) e *batch size* pari a 2. L'obiettivo principale è stato quello di costruire una U-Net 3D basata su *patch* di dati volumetrici, mantenendo un equilibrio tra qualità della segmentazione e limitazioni computazionali.

3.6.2 Training, Validation e Test Set

Il dataset BraTS2020 è stato suddiviso in tre sottoinsiemi distinti, al fine di garantire una valutazione imparziale delle prestazioni del modello:

- **Training set** (68%): utilizzato per l'addestramento del modello, il modello utilizza questa porzione di dati per imparare;
- **Validation set** (17%): impiegato durante il training per monitorare le prestazioni del modello su dati non visti e regolare l'apprendimento, prevenendo fenomeni di overfitting;
- **Test set** (15%): utilizzato esclusivamente nella fase finale per valutare la capacità di generalizzazione del modello su dati completamente indipendenti.

Questa suddivisione consente di assicurare che il modello apprenda in maniera efficace senza adattarsi eccessivamente ai dati di addestramento, fornendo una stima realistica delle prestazioni su nuovi pazienti.




Figura 3.5 Suddivisione tipica di un dataset in insiemi di training, validation e test, utilizzata per addestrare e valutare modelli di deep learning. *Figura adattata da Algorithmic Trading 101, "Train Test Split: What It Is, Why It Matters, and How to Do It" (2023)⁽²⁾. Usata a scopo illustrativo accademico.*

3.6.3 Strategie di Training

Per garantire la stabilità dell'addestramento e prevenire fenomeni di overfitting, sono stati adottati due meccanismi di controllo basati su *callback* di **Keras**:

- **Early Stopping:** monitora la metrica di validazione (*Dice coefficient*) e interrompe l'addestramento qualora non si osservino miglioramenti significativi per un numero prefissato di epoche consecutive (*patience*). In questo modo si evita di proseguire il training oltre il punto di saturazione, riducendo il rischio di overfitting e l'uso non necessario di risorse computazionali.
- **Model Checkpoint:** salva automaticamente i pesi del modello che ottengono le migliori prestazioni sul set di validazione, garantendo che al termine del training venga conservata la versione più performante.

Durante ogni epoca di addestramento, il modello viene aggiornato sui dati del *training set* e successivamente valutato sul *validation set*. Quest'ultimo non contribuisce all'aggiornamento dei pesi, ma consente di monitorare la capacità di generalizzazione del modello. L'andamento delle metriche di validazione (in particolare la *validation loss* e il *Dice coefficient*) è stato utilizzato per attivare i meccanismi di *Early Stopping* e *Model Checkpoint*. Queste strategie hanno permesso di ottimizzare il processo di apprendimento, limitando la variabilità dei risultati tra diverse sessioni di training e migliorando la robustezza del modello finale.

3.7 Metriche e Funzioni di Loss

Per l'addestramento e la valutazione del modello sono state adottate funzioni di perdita e metriche basate sul **Dice Similarity Coefficient (DSC)** e sulla **Focal Loss**. Il coefficiente di Dice è stato utilizzato sia come metrica di valutazione, sia come componente principale della funzione di perdita, in quanto misura direttamente la sovrapposizione tra le regioni predette e quelle reali. Nel modello tridimensionale proposto è stata impiegata una **funzione di perdita combinata**, ottenuta come somma pesata di *Weighted Dice Loss* e *Focal Loss*. Tale scelta è motivata dalla necessità di affrontare il marcato **sbilanciamento delle classi** presente nel dataset BraTS in cui le regioni tumorali occupano un numero di voxel nettamente inferiore rispetto al tessuto sano e di dare maggiore importanza ai **voxel difficili da classificare**, come i bordi delle lesioni. L'approccio combinato consente quindi di bilanciare due obiettivi complementari:

- la **Dice Loss** enfatizza la sovrapposizione tra maschera predetta e ground truth, favorendo segmentazioni globalmente coerenti;
- la **Focal Loss** riduce l'impatto dei voxel facilmente classificabili, concentrando l'apprendimento su quelli più complessi o rari.

Questo schema di ottimizzazione si è dimostrato efficace per migliorare la sensibilità nelle regioni tumorali meno rappresentate e garantire una convergenza stabile del modello durante l'addestramento.

3.7.1 Dice Similarity Coefficient (DSC)

Il coefficiente di Dice misura la sovrapposizione tra la maschera predetta X e la ground truth Y :

$$DSC = \frac{2|X \cap Y|}{|X| + |Y|} \quad (3.1)$$

dove:

- X rappresenta la maschera predetta dal modello;
- Y rappresenta la maschera reale (*ground truth*);
- $|X|$ e $|Y|$ indicano rispettivamente il numero di voxel predetti e reali appartenenti alla classe positiva;
- $|X \cap Y|$ rappresenta il numero di voxel correttamente individuati come appartenenti al tumore.

Valori di DSC prossimi a 1 indicano un'elevata sovrapposizione tra predizione e ground truth, mentre valori prossimi a 0 denotano una segmentazione poco accurata.

3.7.2 Dice Loss

La **Dice Loss** è definita come:

$$\mathcal{L}_{Dice} = 1 - DSC(P, G) \quad (3.2)$$

dove:

- P rappresenta la maschera predetta dal modello (probabilità voxel-wise);
- G rappresenta la maschera reale (*ground truth*).

Questa funzione penalizza il modello quando la sovrapposizione tra predizione e ground truth è ridotta. È particolarmente utile nei casi di forte sbilanciamento di classe, come nella segmentazione di tumori di piccole dimensioni rispetto all'intero volume cerebrale.

3.7.3 Focal Loss

La **Focal Loss**, introdotta da Lin et al. (2017), è una variante della cross-entropy definita come:

$$\mathcal{L}_{Focal} = -\alpha \sum_{i=1}^N G_i (1 - P_i)^\gamma \log(P_i) \quad (3.3)$$

dove:

- G_i è il valore reale (*ground truth*) del voxel i -esimo (1 se appartiene alla classe corretta, 0 altrimenti);
- P_i è la probabilità predetta dal modello che il voxel appartenga alla classe corretta;
- α è un fattore di bilanciamento tra le classi;
- γ controlla il grado di focalizzazione sui campioni difficili: valori più elevati di γ riducono l'impatto dei voxel classificati con alta confidenza;
- N è il numero totale di voxel considerati.

Il suo obiettivo è ridurre l'influenza dei voxel facilmente classificabili (ad esempio il tessuto sano) e dare maggiore peso a quelli più difficili o rari, come i margini del tumore. In pratica, quando il modello è già molto sicuro di una predizione corretta, il contributo di quel voxel alla perdita viene ridotto; al contrario, gli errori su voxel incerti o mal classificati vengono amplificati. Questo meccanismo spinge la rete a concentrarsi sulle regioni più complesse, migliorando la segmentazione delle aree tumorali meno rappresentate.

3.7.4 Loss Combinata

La funzione di perdita finale combina le due precedenti:

$$\mathcal{L}_{Combined} = \lambda \cdot \mathcal{L}_{Dice} + (1 - \lambda) \cdot \mathcal{L}_{Focal} \quad (3.4)$$

dove:

- $\mathcal{L}_{Dice}$ rappresenta la perdita basata sulla sovrapposizione globale;
- $\mathcal{L}_{Focal}$ enfatizza i voxel difficili da classificare;
- $\lambda \in [0, 1]$ è un parametro che bilancia il contributo relativo delle due componenti.

La **loss combinata** unisce i vantaggi della *Dice Loss* e della *Focal Loss*, bilanciando la qualità complessiva della segmentazione con la capacità di apprendere dalle regioni meno rappresentate. In particolare, la Dice Loss favorisce una buona sovrapposizione tra predizione e ground truth, mentre la Focal Loss concentra l'apprendimento sui voxel difficili o rari. L'unione delle due consente al modello di mantenere stabilità durante l'addestramento e migliorare la sensibilità sulle classi tumorali minori. In questo lavoro è stato scelto $\lambda = 0.5$, in modo da bilanciare la qualità complessiva della segmentazione (garantita dalla Dice Loss) con la capacità di apprendere efficacemente le regioni meno rappresentate (favorita dalla Focal Loss).

Capitolo 4

Risultati e Discussione

4.1 Risultati Quantitativi

In questa sezione riportiamo i risultati e gli esempi ottenuti dall'addestramento del modello proposto per la segmentazione dei tumori cerebrali sul dataset BraTS2020.

4.1.1 Risultati del Modello

La Tabella 4.1 riporta i risultati della configurazione migliore identificata durante l'addestramento del modello, mostrando le metriche di training e di validazione nella configurazione ottimale.

Tabella 4.1 Prestazioni del modello 3D U-Net durante l'addestramento (configurazione ottimale).

Metrica	Accuracy	Dice (Train)	Loss	Val Accuracy	Dice (Val)	Val Loss
Valore	0.94	0.78	0.11	0.93	0.75	0.13

Tabella 4.2 Metriche di valutazione del modello 3D U-Net sul test set.

Metrica	Valore
Loss	0.3029
Accuracy	0.9319
MeanIoU	0.3750
Dice globale	0.7298
Dice (NCR/NET)	0.6637
Dice (ED)	0.7351
Dice (ET)	0.7907
Precision	0.9325
Sensitivity (Recall)	0.8496
Specificity	0.9845

Rispetto ai valori tipici riportati nelle challenge BraTS (Dice medio ≈ 0.70 – 0.80 per modelli U-Net 3D standard^(4;7;11)), il nostro modello raggiunge prestazioni competitive considerando le limitazioni hardware e la ridotta patch size utilizzata.

4.1.2 Cosa misurano le metriche

Nel problema di segmentazione dei tumori cerebrali distinguiamo tre sotto-regioni principali: **NCR/NET** (nucleo necrotico/non-enhancing), **ED** (edema) ed **ET** (enhancing tumor).

Dice (per classe e globale) misura la sovrapposizione tra la maschera predetta e quella reale (0 = nessuna sovrapposizione, 1 = perfetta coincidenza). È la metrica principale di qualità della segmentazione. Il *Dice globale* è la media dei Dice delle tre classi tumorali (NCR/NET, ED, ET).

Precision indica, tra tutti i voxel predetti come “tumore”, quanti lo sono realmente. Alta precisione significa pochi falsi positivi (segmentazioni “pulite”).

Sensitivity (Recall) indica, tra tutti i voxel realmente tumorali, quanti sono stati correttamente individuati. Alta sensibilità implica pochi falsi negativi (poca sotto-segmentazione).

Specificity misura la capacità del modello di riconoscere correttamente il tessuto sano (background). Nei dati BraTS risulta solitamente elevata, poiché la maggior parte dei voxel appartiene al background.

Interpretazione dei risultati.

- **Dice globale 0.73:** buona sovrapposizione tra la segmentazione predetta e quella reale, indicativa di una segmentazione complessivamente accurata e coerente lungo le tre dimensioni.
- **Dice per classe:** i risultati mostrano prestazioni elevate per **ED (0.73)** e **ET (0.79)**, mentre la classe **NCR/NET (0.66)** risulta più difficile da segmentare, a causa della sua ridotta dimensione e dei contorni poco definiti. L’edema, visibile nelle sequenze FLAIR e T2, è generalmente la regione più facile da riconoscere.
- **Precisione 0.93** e **Specificità 0.98** elevate: il modello tende a evitare falsi positivi, producendo segmentazioni “pulite” e ben delimitate rispetto al tessuto sano.
- **Sensibilità 0.85:** leggermente inferiore alla precisione, indica che il modello può perdere piccole porzioni di tumore in casi più complessi o a basso contrasto, ma riesce comunque a individuare la maggior parte delle regioni patologiche rilevanti.

In sintesi. Il modello 3D tende a evitare sovra-segmentazioni (pochi falsi positivi) mantenendo un buon overlap medio, ma può perdere porzioni di tumore in alcuni pazienti (falsi negativi), specialmente per ET e NCR/NET. Le variazioni tra pazienti riflettono l'eterogeneità clinica tipica dei casi BraTS, in cui la dimensione e la morfologia del tumore possono variare significativamente.

4.1.3 Curve Di Training/Validation

In Figura 4.1 mostriamo l'andamento delle metriche durante l'addestramento: le curve di *loss* (training e validation), la *loss combinata* usata in ottimizzazione, e il *Dice* (training e validation).




Figura 4.1 Andamento delle metriche durante l'addestramento (training e validation).

Cosa si osserva.

- **Fase iniziale.** Nelle prime epoche la *loss* decresce rapidamente mentre il *Dice* aumenta in modo netto: il modello apprende velocemente le strutture principali del tumore.
- **Stabilizzazione.** Dopo circa 3–4 epoche la perdita di validazione si stabilizza e le oscillazioni diventano più contenute, segnalando l'avvio di una fase di convergenza.

- **Gap train–val.** Il divario tra training e validation rimane ridotto, indicando che il modello generalizza correttamente e non mostra segni di *overfitting*.
- **Effetto della Focal Loss.** Le oscillazioni nella loss di validazione sono più evidenti per le classi piccole (ET, NCR/NET): la componente Focal assegna peso maggiore ai voxel rari o difficili, amplificando naturalmente tali variazioni. Si tratta tuttavia di un comportamento atteso e non di un peggioramento reale delle prestazioni.
- **Coerenza tra Combined Loss e Dice.** La loss combinata (Focal + Dice) mostra un andamento coerente con il miglioramento del Dice di validazione, confermando la sua efficacia nel bilanciare le classi sbilanciate.
- **Early Stopping e Model Checkpoint.** Il modello raggiunge prestazioni ottimali intorno alla 10^a–12^a epoca; oltre tale punto non si osservano miglioramenti significativi. L'*Early Stopping* interrompe il training in modo opportuno, prevenendo l'*overfitting* e risparmiando risorse computazionali.

Lettura pratica. In sintesi: (i) calo rapido iniziale seguito da un plateau stabile della validation loss; (ii) gap train–val contenuto; (iii) oscillazioni fisiologiche dovute alle classi più piccole; (iv) coerenza tra minimo della *Combined Loss* e massimo del *Dice* di validazione, a supporto dell'efficacia della loss combinata (Focal + Dice) in un contesto sbilanciato come BraTS.

4.2 Confronto con lo stato dell'arte

Il Dice medio ottenuto dal nostro modello 3D (≈ 0.73) è comparabile con i risultati riportati in letteratura per architetture U-Net standard su BraTS2020, che oscillano tra 0.68 e 0.75 a seconda della configurazione e del pre-processing^(4;7;11). Le varianti più avanzate, come nnU-Net⁽¹²⁾ o Attention U-Net⁽⁵⁾, raggiungono valori superiori (0.80–0.85), ma a fronte di una complessità computazionale molto maggiore e di un numero di parametri significativamente più alto. Il nostro modello si colloca quindi come una soluzione intermedia: una pipeline leggera e riproducibile, adatta a scenari con risorse hardware limitate, capace di fornire segmentazioni coerenti e generalizzabili su più soggetti.

Capitolo 5

Conclusione

5.1 Conclusioni e considerazioni finali

Il lavoro svolto ha avuto come obiettivo principale la progettazione e la sperimentazione di un modello di segmentazione automatica dei tumori cerebrali basato su architettura **3D U-Net**, applicato al dataset **BraTS2020**. A partire da una versione bidimensionale preliminare, il modello è stato esteso in 3D per integrare il contesto volumetrico, ottenendo segmentazioni più coerenti e una migliore distinzione tra le sotto-regioni tumorali (*NCR/NET*, *ED*, *ET*).

Dal punto di vista quantitativo, il modello ha raggiunto un **Dice globale pari a 0.73**, con valori di precisione (0.93), sensibilità (0.85) e specificità (0.98). Tali risultati sono competitivi rispetto agli approcci U-Net standard riportati in letteratura, che tipicamente ottengono Dice compresi tra 0.70 e 0.80^(4;7;11). Pur non raggiungendo le prestazioni dei modelli più complessi (come nnU-Net⁽¹²⁾ o Attention U-Net⁽⁵⁾), la rete proposta si distingue per la **semplicità architetture**, la stabilità del training e la capacità di generalizzazione ottenuta anche in presenza di risorse computazionali limitate.

Un ulteriore contributo significativo è rappresentato dall'adozione di una **loss combinata Focal+Dice**, che ha permesso di bilanciare efficacemente le classi fortemente sbilanciate del dataset, focalizzando l'apprendimento sulle regioni meno rappresentate (*ET*, *NCR/NET*). Insieme alle strategie di *data augmentation* volumetrica e all'uso di patch tridimensionali (64, 64, 64), ciò ha reso il modello robusto e capace di adattarsi alla variabilità anatomica e patologica tipica dei pazienti BraTS.

Dal punto di vista qualitativo, le predizioni del modello mostrano una segmentazione **visivamente coerente lungo l'asse z**, con bordi più regolari e una migliore continuità spaziale rispetto al modello 2D. Questo aspetto è cruciale per una possibile applicazione clinica, poiché garantisce la **ricostruzione volumetrica realistica** delle lesioni, utile per la pianificazione chirurgica e la valutazione del follow-up radiologico.

Nonostante i risultati promettenti, il modello presenta ancora alcune limitazioni. In particolare, le prestazioni sulle classi *ET* e *NCR/NET* risultano inferiori rispetto all'edema (*ED*), principalmente a causa della loro ridotta dimensione e dell'eterogeneità del segnale. Inoltre, la dimensione delle patch e del batch size è stata vincolata dalle

risorse GPU disponibili, limitando la capacità del modello di apprendere contesto a lungo raggio. Infine, non è stato introdotto alcun **post-processing morfologico** (es. CRF, connected components filtering), che potrebbe migliorare la pulizia delle maschere finali e ridurre le piccole false predizioni isolate.

Nel complesso, il modello 3D U-Net sviluppato rappresenta un **compromesso bilanciato tra accuratezza e sostenibilità computazionale**, con una pipeline riproducibile e adattabile anche a contesti con risorse hardware limitate. Il lavoro costituisce una solida base per la futura integrazione di moduli più sofisticati e per l'eventuale traslazione del sistema in un ambiente clinico reale, a supporto dei radiologi nella diagnosi e nel monitoraggio dei tumori cerebrali.

Bibliografia

- [1] Feriel Amor, Hiba Mzoughi, Ines Njeh, and Mohamed Ben Slima. Review of mri brain tumor segmentation and mgmt promoter classification methods on brats dataset based on deep learning. *Proceedings of the 7th IEEE International Conference on Advanced Technologies, Signal and Image Processing (ATSIP)*, 2024.
- [2] AlgoTrading101. Train test split: What it is, why it matters, and how to do it, 2023. Accessed: 2025-10-08.
- [3] Manpreet Kaur, Rajeev Singh, et al. Mri-based brain tumor segmentation using deep learning and hybrid models: a review. *BMC Medical Imaging*, 23(1):131, 2023.
- [4] Sunita Roy, Rikan Saha, Suvarthi Sarkar, Ranjan Mehera, Rajat Kumar Pal, and Samir Kumar Bandyopadhyay. Brain tumour segmentation using s-net and sa-net. *IEEE Access*, 11:28658–28673, 2023.
- [5] Abrar Taher and Sabiha Anan. Multiclass brain tumor classification and segmentation from 2d mr images: A deep learning approach using residual attention u-net. *Proceedings of the 26th International Conference on Computer and Information Technology (ICCIT)*, 2023.
- [6] Lakshmi Namratha Vempaty, Gururaj L. Kulkarni, Manjusha Tatiya, Pankaj Singh, Anurag Shrivastava, and Vijay Saxena. Apply agglomerative algorithm and vgg16 on brain tumor segmentation dataset to be used brats. In *Proceedings of the 6th International Conference on Contemporary Computing and Informatics (IC3I)*. IEEE, 2023.
- [7] Michal Futrega, Alexandre Milesi, Michal Marcinkiewicz, and Pablo Ribalta. Optimized u-net for brain tumor segmentation. *arXiv preprint arXiv:2110.03352*, 2021. Winner of BraTS21 validation phase.
- [8] Khan Muhammad, Salman Khan, Javier Del Ser, and Victor Hugo C. de Albuquerque. Deep learning for multigrade brain tumor classification in smart healthcare systems: A prospective survey. *IEEE Transactions on Neural Networks and Learning Systems*, 32(2):507–522, 2021.
- [9] Spyridon Bakas, Bjoern H. Menze, Mauricio Reyes, Andras Jakab, Stefan Bauer, Markus Rempfler, and Alessandro Crimi. Brain tumor segmentation (brats) 2020 dataset. <https://www.kaggle.com/datasets/awsaf49/brats20-dataset-training-validation>, 2020.

- [10] Nameirakpam Dhanachandra, K Manglem, and Y Chanu. Multimodal mri brain tumor image segmentation using sparse subspace clustering algorithm. *ResearchGate Preprint*, 2020. Accessed: 2025-10-08.
- [11] Milad Ghaffari, Arcot Sowmya, and Richard Oliver. Automated brain tumor segmentation using multimodal brain scans: A survey based on models submitted to the brats challenge. *IEEE Reviews in Biomedical Engineering*, 13:156–168, 2020.
- [12] Spyridon Bakas, Mauricio Reyes, Andras Jakab, Stefan Bauer, Markus Rempfler, Alessandro Crimi, Russell Takeshi Shinohara, Christoph Berger, Sung Min Ha, Martin Rozycki, et al. Identifying the best machine learning algorithms for brain tumor segmentation, progression assessment, and overall survival prediction in the brats challenge. *arXiv preprint arXiv:1811.02629*, 2019.
- [13] Spyridon Bakas, Hamed Akbari, Aristeidis Sotiras, Michel Bilello, Martin Rozycki, Justin Kirby, John Freymann, Keyvan Farahani, and Christos Davatzikos. Advancing the cancer genome atlas glioma mri collections with expert segmentation labels and radiomic features. *Scientific Data*, 4:170117, 2017.
- [14] Sérgio Pereira, Adriano Pinto, Victor Alves, and Carlos A Silva. Brain tumor segmentation using convolutional neural networks in mri images. *IEEE Transactions on Medical Imaging*, 35(5):1240–1251, 2016.
- [15] Bjoern H Menze, Andras Jakab, Stefan Bauer, Jayashree Kalpathy-Cramer, Keyvan Farahani, Justin Kirby, Yuliya Burren, Nicole Porz, Johannes Slotboom, Roland Wiest, et al. The multimodal brain tumor image segmentation benchmark (brats). *IEEE Transactions on Medical Imaging*, 34(10):1993–2024, 2015.
- [16] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net: Convolutional networks for biomedical image segmentation. In *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, pages 234–241. Springer, 2015.